Q-learning 기반 선택적 정상 기준선 갱신을 통한 금속 산업 전력 이상탐지

김주희 , 백민우 , 길기훈 , * 이상금

* 국립한밭대학교

EcoAI Lab

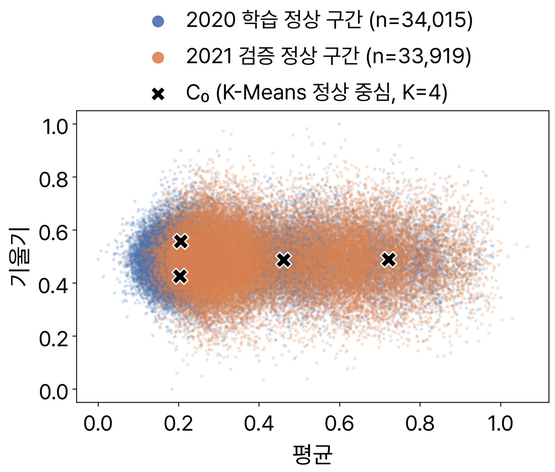
KICS 한국통신학회 The Korean Institute of Communications and Information Sciences

1. 요약

- **[문제]** 기준선 고정 (Static): 정상 패턴 변화에 적응하기 어려움 . 매 시점 갱신 (Always Update): 이상 데이터가 기준선에 반영될 위험
- **[방법]** 거리 기반 이상 판정과 고정 임계값 τ^* 유지 . Q-learning 은 상태에 따라 정상 중심의 유지 (Freeze)· 갱신 (Update) 만 선택
- **[결과]** 2022 년 합성 이상 평가 F1 **0.534±0.010** 으로 Always Update(0.283)·Threshold-Gate(0.446) 보다 높으나 , Static(0.526) 과의 차이는 작고 합성 이상 실현에 따라 순위가 바뀜

2. 연구 배경 및 문제

- **[배경]** 설비 운전 상태 · 생산 일정 변화로 정상 전력 사용 패턴 자체가 변할 수 있음 . 정상 중심까지의 거리를 이상 점수로 쓰는 방식에서는 기준선 갱신 시점 결정이 문제가 됨
- **[차별점]** 탐지 임계값을 동적으로 조정한 기존 RL 연구 [1] 와 달리 , 임계값은 고정하고 정상 기준선의 갱신 여부만 학습함



[그림 1] 학습 · 검증 정상 구간 분포

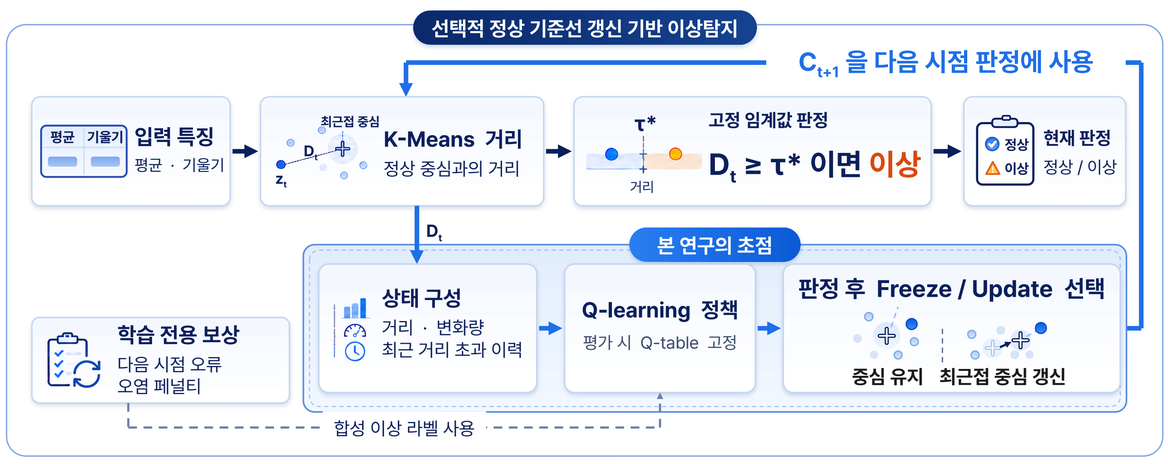
2020 Train 과 2021 Validation 의 정상 구간을 Train 기준 스케일러로 변환한 (평균 , 기울기) 공간에서 비교함

Train 정상 거리의 95 분위 경계 D_{q95}(=0.1660) 를 넘는 비율 : Train **5.00%** → Validation **13.69%**

D_{q95} 는 분포 비교용 경계이며 , 실제 판정 임계값 τ^* 와 다름

→ 학습 시점의 정상 기준이 이후 분포를 충분히 대표하지 못할 수 있음

3. 전체 연구 흐름



[그림 2] 현재 시점 판정과 다음 시점 기준선 갱신 구조

- **[목적 · 범위]** 고정된 거리 기반 판정을 유지하면서 , 정상 패턴 변화와 기준선 오염을 고려해 중심 갱신 여부를 선택함
- **[작동 흐름]** 현재 시점 판정 → 정상 중심 유지 · 갱신 선택 → 다음 시점 판정에 반영

4. 선택적 정상 기준선 갱신 방법론

① 상태 구성

거리 D_t
최근접 정상 중심까지의 거리

변화량 Δ_t
$\Delta_t = \|z_t - z_{t-1}\|_2$

최근 이력 H_t
현재 시점 제외 직전 최대 6 시점 중 $D \geq D_{q95}$ 비율

각 Low/Mid/High → 27 개 상태

② 행동 선택

Freeze
z_t
모든 중심 유지

Update
z_t
최근접 중심만 갱신

$c_{k^*,t+1} = (1-\eta)c_{k^*,t} + \eta z_t,\ \eta = 0.05$

③ 학습 보상

라벨 : 정상 이상

다음 시점 탐지 오류
[t, t+1]
t−1 t t+1
라벨 : 이상
판정 : 정상
불일치
t+1 의 라벨과 판정 비교

오염 갱신 페널티
현재 윈도우 [t−1, t]
t−1 t
L = 2
이상 포함 → u_t=1

$$r_{t+1} = -L_{det}(t+1) - \lambda \cdot 1[a_t = \text{Update} \wedge u_t = 1]$$

[그림 3] Q-learning 의 상태 · 행동 · 보상 구성

- **[평가]** 초기 중심 C_0 에서 시작 , Q-table 은 고정 (greedy 선택) 하고 정상 중심은 선택한 행동에 따라 유지 · 갱신함

5. 실험 설계

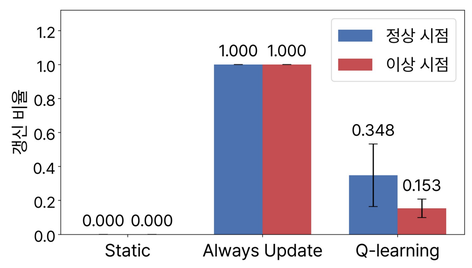
- **[데이터]** **실제 정상 전력 시계열에 합성 이상을 주입한 평가**
  금속 산업 단일 전력 미터 (15 분 간격). 이상 유형 (이벤트 수 기준): Point 40%, Gradual 20%, State-change 40%. 이상 시점 비율 : 연도별 약 3%
- **[특징 · 기준선]** 평균 · 기울기 (L=2, 30 분) 를 2020 정상 구간 기준으로 Min-Max 정규화하고 , 같은 구간의 K-Means(K=4) 로 초기 기준선 C_0 를 구축함

비교 방법	정상 중심 갱신 규칙 (판정 규칙 · 고정 임계값 τ^* 는 모든 방법 동일)
Static	항상 Freeze
Always Update	항상 Update
Threshold-Gate	$D_t < \tau^*$ 일 때 Update, 그 외 Freeze
Q-learning	상태에 따라 Freeze/Update 선택

- **[학습 · 평가]**
  임계값 선정 (2021 검증): Static 의 검증 F1 이 최대인 β^*=2.22 선택 . $\tau^* = \beta^* \cdot D_{q95}$ 를 모든 방법에 동일하게 적용
  정책 학습 (2020): 전체 윈도우로 1-step Q-learning 학습 (α=0.10, γ=0.9, ε=0.20, λ=1.0, 10 epochs, 시드 4 개)
  최종 평가 (2022): 윈도우 마지막 시점 라벨 기준 Precision·Recall·F1 산출 . 2022 데이터는 최종 평가에만 사용

6. 실험 결과

6.1 갱신 행동 (2021 Validation)



[그림 4] 시점 유형별 갱신 비율

정상 / 이상 시점 : 윈도우 마지막 시점 라벨 기준 . 오차 막대 : 4 개 시드 표본 표준편차

이상 시점 갱신 비율 **0.153** 은 정상 시점 **0.348** 의 약 44%(4 개 시드 동일 경향)

중심 이동량 (4 개 중심과 C_0 사이 거리 평균) 의 시간 평균 : Q-learning **0.215**, Always Update **0.778**

6.2 이상탐지 성능 (2022 평가)

[표 1] 2022 년 합성 이상 평가 성능 (Q-learning: 4 개 시드 평균 ± 표준편차)

방법	Precision	Recall	F1
Static	0.795	0.392	0.526
Always Update	0.624	0.183	0.283
Threshold-Gate	0.878	0.299	0.446
Q-learning (제안)	0.879±0.030	0.384±0.007	0.534±0.010

- Q-learning 의 F1 은 Always Update·Threshold-Gate 보다 높음 . 단 , Static 대비 F1 차이 (**0.008**) 는 시드 간 표준편차 (**0.010**) 보다 작음
- 독립적으로 추출한 다른 합성 이상 실현에서는 Static **0.548**, Q-learning **0.505±0.076** 으로 순위가 바뀜

7. 결론 및 향후 과제

- **[기여]** 거리 기반 판정은 유지하고 , 정상 기준선의 Freeze/Update 선택을 상태 기반 의사결정 문제로 구성함
- **[관찰]** 이상 시점 갱신 비율은 **0.153** 으로 정상 시점 **0.348** 보다 낮음 . 최종 중심 이동량은 Q-learning **0.311**, Always Update **1.343** 임
- **[한계]** Static 과의 F1 차이가 작고 실현에 따라 순위가 바뀌어 , 선택적 갱신 정책의 가능성을 확인한 단계임 . 보상에 합성 이상 라벨을 사용함
- **[향후 과제]** 시드 수와 독립 실현 수를 늘려 반복 검증 . 합성 이상 라벨 없이 학습할 수 있는 보상 설계 검토

[1] X. Yang et al., "Agent-based dynamic thresholding for adaptive anomaly detection using reinforcement learning," Neural Comput. Appl., vol. 37, no. 23, pp. 18775–18791, 2025.

본 연구는 산업통상자원부 (MOTIE) 와 한국에너지기술평가원 (KETEP) 의 지원을 받아 수행한 연구 과제입니다 . (No. RS2023-00237018) **발표자 :** 김주희 (joo060613@gmail.com)